הסתברות — דף בסיס מסודר

משתנים מקריים, פונקציות הסתברות, מומנטים והתפלגויות חשובות

- מהו משתנה מקרי?
- בדיד ורציף
- התפלגות מצטברת
- תוחלת ושונות
- מומנטים
- התפלגויות חשובות
- Gamma ו־Erlang
- תרגול

מהו משתנה מקרי?

הגדרה

משתנה מקרי הוא פונקציה שמתאימה לכל תוצאה אפשרית של ניסוי אקראי מספר ממשי. כלומר, הוא לוקח תוצאה מהעולם האקראי ומתרגם אותה למספר שאפשר לחשב איתו.

$$X : \Omega \to \mathbb{R}$$

כאן Ω הוא מרחב המדגם — אוסף כל התוצאות האפשריות של הניסוי. המשתנה המקרי X אינו בהכרח "התוצאה עצמה", אלא ערך מספרי שמוגדר מתוך התוצאה.

דוגמה

מטילים שתי קוביות. אפשר להגדיר את X להיות סכום התוצאות. אם התקבלה התוצאה $(3, 5)$, אז:

$$X(3, 5) = 3 + 5 = 8$$

משתנה מקרי בדיד ומשתנה מקרי רציף

משתנה מקרי בדיד

משתנה מקרי בדיד הוא משתנה שיכול לקבל מספר סופי או בן־מנייה של ערכים.

דוגמאות:

- תוצאה של הטלת קובייה
- מספר הצלחות מתוך n ניסיונות
- מספר לקוחות שמגיעים לחנות בשעה

משתנה מקרי רציף

משתנה מקרי רציף הוא משתנה שיכול לקבל ערכים על פני רצף.

דוגמאות:

- זמן המתנה
- גובה של אדם
- אורך חיים של רכיב
- טמפרטורה

פונקציית הסתברות במקרה הבדיד

עבור משתנה מקרי בדיד משתמשים בפונקציית הסתברות, שמסומנת בדרך כלל $p_X(x)$. היא נותנת את ההסתברות שהמשתנה יקבל בדיוק את הערך x.

$$p_X(x) = P(X = x)$$

התכונות המרכזיות הן:

$$p_X(x) \geq 0 \qquad \text{and} \qquad \sum_x p_X(x) = 1$$

כלומר, כל הסתברות היא אי־שלילית, וסכום כל ההסתברויות על פני כל הערכים האפשריים הוא 1.

פונקציית צפיפות במקרה הרציף

עבור משתנה מקרי רציף משתמשים בפונקציית צפיפות, שמסומנת בדרך כלל $f_X(x)$. במקרה רציף, ההסתברות לקבל ערך מדויק היא בדרך כלל אפס:

$$P(X = x) = 0$$

לכן הסתברויות מחושבות כשטחים מתחת לגרף הצפיפות:

$$P(a \leq X \leq b) = \int_a^b f_X(x)\,dx$$

התכונות המרכזיות הן:

$$f_X(x) \geq 0 \qquad \text{and} \qquad \int_{-\infty}^{\infty} f_X(x)\,dx = 1$$

אינטואיציה חשובה

במקרה בדיד, הגובה של פונקציית ההסתברות הוא עצמו הסתברות. במקרה רציף, הגובה של הצפיפות אינו הסתברות בפני עצמו; השטח מתחת לגרף הוא ההסתברות.

פונקציית התפלגות מצטברת

פונקציית ההתפלגות המצטברת, או CDF, מסומנת $F_X(x)$. היא מתארת את ההסתברות שהמשתנה המקרי יקבל ערך קטן או שווה ל־x.

$$F_X(x) = P(X \leq x)$$

במקרה הבדיד

$$F_X(x) = \sum_{t \leq x} p_X(t)$$

במקרה הרציף

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,dt$$

אם X רציף והפונקציה גזירה בנקודה, אז הצפיפות מתקבלת מהנגזרת של פונקציית ההתפלגות המצטברת:

$$f_X(x) = F_X'(x)$$

תכונות חשובות

- $0 \leq F_X(x) \leq 1$
- $F_X(x)$ אינה יורדת
- $\lim_{x \to -\infty} F_X(x) = 0$
- $\lim_{x \to \infty} F_X(x) = 1$

תוחלת ושונות

תוחלת

התוחלת היא הממוצע התיאורטי של המשתנה המקרי. אם חוזרים על הניסוי הרבה מאוד פעמים, התוחלת מתארת את הערך הממוצע שאליו צפוי להתקרב הממוצע בפועל.

במקרה בדיד:

$$E[X] = \sum_{x} x\, p_X(x)$$

במקרה רציף:

$$E[X] = \int_{-\infty}^{\infty} x\, f_X(x)\, dx$$

דוגמה קצרה

בהטלת קובייה הוגנת, X הוא המספר שיצא. לכן:

$$E[X] = \frac{1+2+3+4+5+6}{6} = 3.5$$

שים לב שהתוחלת לא חייבת להיות ערך שהמשתנה באמת יכול לקבל. בקובייה אי אפשר לקבל 3.5, אבל זה עדיין הממוצע התיאורטי.

שונות

השונות מודדת את הפיזור של המשתנה המקרי סביב התוחלת. אם התוחלת היא $\mu = E[X]$, אז השונות מוגדרת כך:

$$\mathbf{Var}(X) = E[(X - \mu)^2]$$

נוסחה שימושית מאוד לחישוב שונות היא:

$$\mathbf{Var}(X) = E[X^2] - (E[X])^2$$

סטיית התקן היא השורש של השונות:

$$\sigma = \sqrt{\mathbf{Var}(X)}$$

תכונות שימושיות של תוחלת ושונות

$$E[aX + b] = a\,E[X] + b$$

$$Var(aX + b) = a^2\,Var(X)$$

$$Var(E[X]) = 0$$

$$E(Var(X)) = Var(X)$$

מומנטים של משתנה מקרי

מומנטים הם דרך כללית לתאר תכונות של התפלגות באמצעות תוחלות של חזקות. הם מאפשרים לתפוס מידע על מרכז ההתפלגות, הפיזור שלה, ולעיתים גם על הצורה שלה.

מומנט סביב אפס

המומנט ה־k סביב אפס מוגדר כך:

$$m_k = E[X^k]$$

למשל:

- המומנט הראשון הוא $m_1 = E[X]$
- המומנט השני הוא $m_2 = E[X^2]$
- המומנט השלישי הוא $m_3 = E[X^3]$

מומנט מרכזי

מומנט מרכזי מחושב סביב התוחלת μ, ולא סביב אפס:

$$\mu_k = E[(X - \mu)^k]$$

בפרט, המומנט המרכזי השני הוא השונות:

$$\mu_2 = E[(X - \mu)^2] = \mathrm{Var}(X)$$

איך תוחלת ושונות הן פונקציות של מומנטים?

התוחלת היא ממש המומנט הראשון סביב אפס:

$$E[X] = m_1$$

השונות היא פונקציה של המומנט הראשון והשני:

$$\mathbf{Var}(X) = E[X^2] - (E[X])^2 = m_2 - m_1^2$$

הרעיון המרכזי

מומנטים הם "חומרי הגלם" שמתוכם אפשר לבנות גדלים חשובים. התוחלת משתמשת במומנט הראשון, והשונות משתמשת במומנט הראשון והשני.

משתנים מקריים מיוחדים

טבלה מסכמת

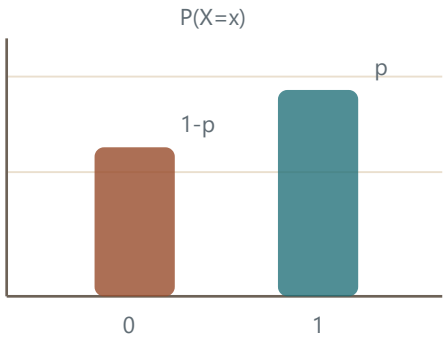
התפלגות	סימון	מה היא מתארת?	תוחלת	שונות
ברנולי	$X \sim \text{Bernoulli}(p)$	ניסוי יחיד עם הצלחה או כישלון	p	$p(1-p)$
בינומית	$X \sim \text{Binomial}(n, p)$	מספר הצלחות מתוך n ניסויי ברנולי בלתי תלויים	np	$np(1-p)$
גיאומטרית	$X \sim \text{Geometric}(p)$	מספר הניסיונות עד ההצלחה הראשונה	$\frac{1}{p}$	$\frac{1-p}{p^2}$
מעריכית	$X \sim \text{Exponential}(\lambda)$	זמן המתנה עד אירוע אחד	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
נורמלית	$X \sim N(\mu, \sigma^2)$	התפלגות פעמון סימטרית סביב μ	μ	σ^2

תרשימים אינטואיטיביים

ויזואליזציה של התפלגויות שונות.

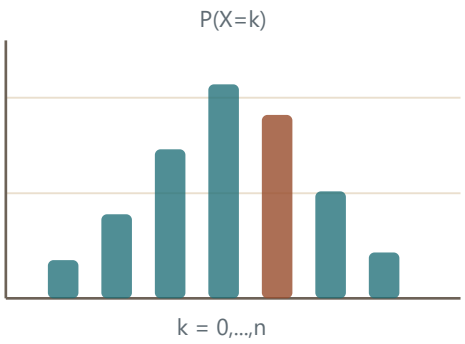
ברנולי

שתי עמודות בלבד: כישלון 0 והצלחה 1.



בינומית

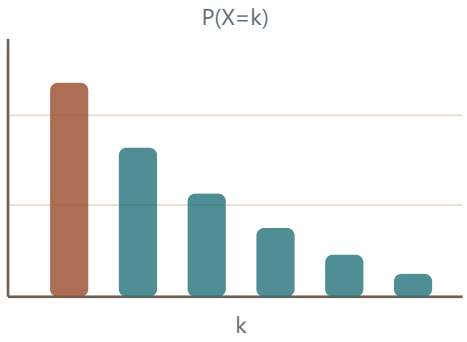
מספר הצלחות מתוך כמה ניסויים; לרוב מתקבלת צורה של "גבעה" בדידה.



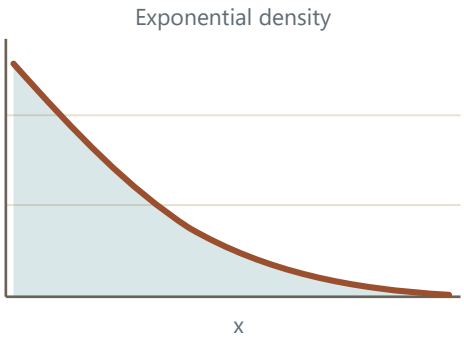
גיאומטרית

מעריכית

ההסתברות יורדת ככל שמחכים יותר להצלחה הראשונה.

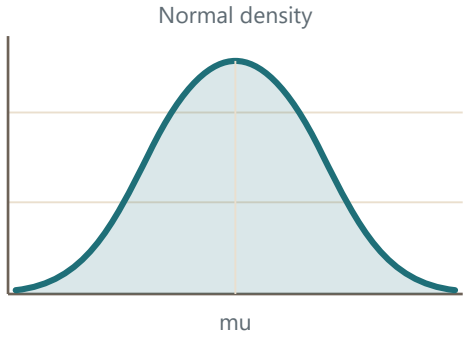


צפיפות יורדת: זמן קצר עד האירוע סביר יותר מזמן ארוך.



נורמלית

פעמון סימטרי סביב התוחלת μ.



ברנולי

התפלגות ברנולי מתארת ניסוי עם שתי תוצאות בלבד: הצלחה שמסומנת 1, וכישלון שמסומן 0. אם p היא הסתברות ההצלחה:

$$P(X=1)=p, \qquad P(X=0)=1-p$$

$$E[X]=p, \qquad \mathrm{Var}(X)=p(1-p)$$

בינומית

התפלגות בינומית מתארת מספר הצלחות מתוך n ניסויי ברנולי בלתי תלויים, כאשר בכל ניסוי הסתברות ההצלחה היא p.

$$P(X=k)=\binom{n}{k}p^k(1-p)^{n-k}, \qquad k=0,1,\dots,n$$

$$E[X]=np, \qquad \mathrm{Var}(X)=np(1-p)$$

גיאומטרית

התפלגות גיאומטרית מתארת את מספר הניסיונות עד ההצלחה הראשונה. כאן נשתמש בגרסה שבה X מקבל ערכים $1,2,3,\dots$.

$$P(X=k)=(1-p)^{k-1}p, \qquad k=1,2,3,\dots$$

$$E[X]=\frac{1}{p}, \qquad \mathrm{Var}(X)=\frac{1-p}{p^2}$$

מעריכית

התפלגות מעריכית היא התפלגות רציפה שמתארת זמן המתנה עד שאירוע מתרחש. הפרמטר λ נקרא קצב.

$$f_X(x)=\lambda e^{-\lambda x}, \qquad x\geq 0$$

$$E[X]=\frac{1}{\lambda}, \qquad \mathrm{Var}(X)=\frac{1}{\lambda^2}$$

חוסר זיכרון

להתפלגות מעריכית יש תכונת חוסר זיכרון: אם כבר חיכינו זמן מסוים, זמן ההמתנה הנוסף מתפלג כמו זמן המתנה חדש.

הקשר לתהליך פואסון

דרך חשובה להבין משתנה מקרי מעריכי היא בעזרת תהליך פואסון. אם אירועים מתרחשים בקצב קבוע λ ובאופן בלתי תלוי לאורך זמן, אז מספר האירועים עד זמן t מתפלג פואסונית:

$$N(t) \sim \text{Poisson}(\lambda t)$$

במקרה כזה, זמן ההמתנה עד האירוע הראשון מתפלג מעריכית:

$$T_1 \sim \text{Exponential}(\lambda)$$

לכן יש שתי דרכים שקולות להסתכל על אותה תופעה: פואסון סופר כמה אירועים התרחשו בפרק זמן נתון, ואילו מעריכי מודד כמה זמן מחכים עד האירוע הבא.

$$P(T_1 > t) = P(N(t) = 0) = e^{-\lambda t}$$

נורמלית

ההתפלגות הנורמלית היא התפלגות רציפה מרכזית מאוד בהסתברות ובסטטיסטיקה. היא סימטרית סביב התוחלת, ויש לה צורת פעמון.

$$X \sim N(\mu, \sigma^2)$$

המשתנה הנורמלי הסטנדרטי הוא:

$$Z \sim N(0,1)$$

כדי להעביר משתנה נורמלי לצורה סטנדרטית משתמשים בנרמול:

$$Z = \frac{X - \mu}{\sigma}$$

משפט הגבול המרכזי

משפט הגבול המרכזי אומר שבמצבים רבים, סכום או ממוצע של הרבה משתנים מקריים בלתי תלויים ודומים בהתפלגות מתקרב להתפלגות נורמלית.

אם $X_1, X_2, \ldots, X_n$ הם משתנים מקריים בלתי תלויים ושווי־התפלגות, עם תוחלת μ ושונות σ^2, אז עבור n גדול:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

אינטואיטיבית: גם אם המשתנים המקוריים אינם נורמליים, הממוצע שלהם נוטה לקבל צורה נורמלית כאשר מספר המשתנים גדול.

התפלגות Gamma והקשר ל־Erlang

התפלגות Gamma היא התפלגות רציפה וחיובית, כלומר היא מוגדרת עבור ערכים $x \geq 0$. היא שימושית במיוחד לתיאור זמני המתנה, סכומים של זמני המתנה, וזמנים עד להתרחשות של כמה אירועים.

הגדרה

נשתמש בפרמטריזציה של צורה וקצב:

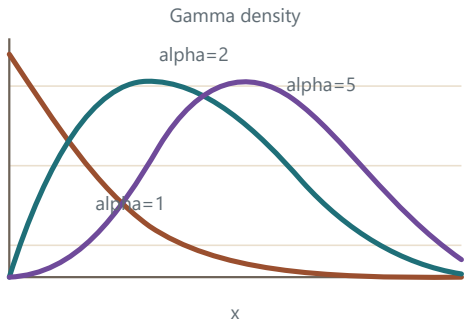
$$X \sim \text{Gamma}(\alpha, \lambda)$$

כאשר $\alpha > 0$ הוא פרמטר הצורה, ו־$\lambda > 0$ הוא פרמטר הקצב.

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \qquad x \geq 0$$

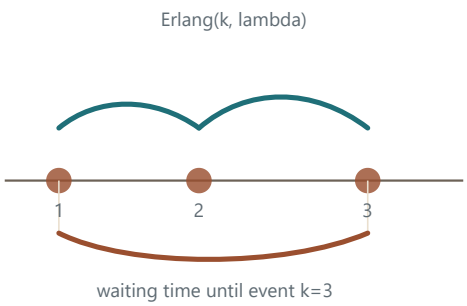
Gamma עבור פרמטרי צורה שונים

כאשר λ קבוע, הגדלת α מזיזה את המסה ימינה ומשנה את צורת העקומה.



Erlang כ־Gamma שלם

Erlang מתקבלת כאשר $\alpha = k$ הוא מספר שלם. היא מתארת זמן עד האירוע ה־k.



פונקציית Gamma

$\Gamma(\alpha)$ היא פונקציית Gamma, שמכלילה את מושג העצרת. עבור מספר טבעי n:

$$\Gamma(n) = (n-1)!$$

למשל:

$$\Gamma(1) = 1, \qquad \Gamma(2) = 1!, \qquad \Gamma(3) = 2!$$

תוחלת ושונות

$$E[X] = \frac{\alpha}{\lambda}$$

$$\mathrm{Var}(X) = \frac{\alpha}{\lambda^2}$$

האינטואיציה של Gamma

הדרך הכי טבעית להבין את המשפחה הזאת מתחילה דווקא מ־Erlang: אם משתנה מעריכי מתאר זמן המתנה עד אירוע אחד, אז סכום של כמה זמני המתנה מעריכיים בלתי תלויים מתאר זמן המתנה עד כמה אירועים.

אם:

$$X_1, X_2, \ldots, X_k \sim \mathrm{Exponential}(\lambda)$$

בלתי תלויים, אז:

$$X_1 + X_2 + \cdots + X_k \sim \mathrm{Gamma}(k, \lambda)$$

כאשר k הוא מספר שלם חיובי, יש כאן פרשנות ישירה וברורה: זהו סכום של k משתנים מעריכיים, או זמן המתנה עד האירוע ה־k. אבל כאשר פרמטר הצורה של Gamma הוא α שאינו שלם, כבר קשה לפרש את ההתפלגות כסכום של "מספר לא שלם" של זמני המתנה מעריכיים. במקרה כזה Gamma היא בעיקר הכללה מתמטית רציפה של Erlang.

הקשר ל־Erlang

התפלגות Erlang היא מקרה פרטי של Gamma שבו פרמטר הצורה הוא מספר שלם חיובי. לכן ל־Erlang יש פרשנות הסתברותית פשוטה במיוחד: סכום של k משתנים מעריכיים בלתי תלויים בעלי אותו קצב λ.

$$\mathbf{Erlang}(k, \lambda) = \mathbf{Gamma}(k, \lambda), \qquad k \in \mathbb{N}$$

אם אירועים מתרחשים לפי תהליך פואסון בקצב λ, אז:

- הזמן עד האירוע הראשון מתפלג מעריכית.
- הזמן עד האירוע ה־k מתפלג Erlang.
- Gamma עם α לא שלם היא הכללה מתמטית, ולא סכום ישיר של מספר שלם של מעריכיים.

$$\mathbf{Exponential}(\lambda) = \mathbf{Gamma}(1, \lambda) = \mathbf{Erlang}(1, \lambda)$$

סיכום אינטואיטיבי

- מעריכית: זמן עד אירוע אחד.
- Erlang: סכום של k משתנים מעריכיים, ולכן זמן עד k אירועים.
- Gamma: הכללה של Erlang; כאשר α אינו שלם, הפרשנות כסכום מעריכיים כבר אינה ישירה.

תרגילים לתרגול

התרגילים הבאים נועדו לבדוק הבנה בסיסית של ההתפלגויות המיוחדות. לכל תרגיל מצורפת תשובה קצרה, כדי שיהיה אפשר ללמוד גם מהפתרון.

תרגילי חימום

1 במפעל בודקים רכיב אחד. ההסתברות שהרכיב תקין היא 0.92. נגדיר $X = 1$ אם הרכיב תקין, ו־$X = 0$ אחרת. מהי ההתפלגות של X, ומהן התוחלת והשונות?

$X \sim \text{Bernoulli}(0.92)$, ולכן $E[X] = 0.92$ ו־$\text{Var}(X) = 0.92 \cdot 0.08 = 0.0736$.

2 מטילים מטבע הוגן 12 פעמים. נגדיר X כמספר הפעמים שיצא "עץ". מהי ההתפלגות של X, ומהי ההסתברות לקבל בדיוק 7 פעמים "עץ"?

$X \sim \text{Binomial}(12, 0.5)$, ולכן

$$P(X = 7) = \binom{12}{7}(0.5)^7(0.5)^5 = \binom{12}{7}(0.5)^{12}.$$

3 ההסתברות לקלוע לסל בזריקה אחת היא $p = 0.4$. נגדיר X כמספר הזריקות עד הקליעה הראשונה. מהי $P(X = 3)$?

$X \sim \text{Geometric}(0.4)$, ולכן

$$P(X = 3) = (1 - 0.4)^2 \cdot 0.4 = 0.6^2 \cdot 0.4 = 0.144.$$

תרגילי תוחלת ושונות

1 מספר התקלות ביום במערכת מסוימת מתואר בקירוב על ידי $X \sim \text{Binomial}(20, 0.1)$. חשבו את $E[X]$ ואת $\text{Var}(X)$.

$$E[X] = np = 20 \cdot 0.1 = 2$$

$$\mathrm{Var}(X) = np(1-p) = 20 \cdot 0.1 \cdot 0.9 = 1.8.$$

2 זמן ההמתנה לשיחת טלפון מתפלג מעריכית עם קצב $\lambda = 3$ שיחות לשעה. מהי תוחלת זמן ההמתנה? מהי השונות?

אם $X \sim \mathrm{Exponential}(3)$, אז

$$E[X] = \frac{1}{3}\ \text{hour} = 20\ \text{minutes}$$

וגם

$$\mathrm{Var}(X) = \frac{1}{3^2} = \frac{1}{9}\ \text{hours}^2.$$

3 נתון משתנה מקרי עם $E[X] = 4$ ו־$E[X^2] = 25$. חשבו את השונות באמצעות מומנטים.

$$\mathrm{Var}(X) = E[X^2] - (E[X])^2 = 25 - 4^2 = 9.$$

תרגילי Gamma ו־Erlang

1 זמן ההמתנה עד אירוע אחד מתפלג מעריכית עם קצב $\lambda = 2$. מהי ההתפלגות של הזמן עד האירוע השלישי?

הזמן עד האירוע השלישי הוא סכום של שלושה זמני המתנה מעריכיים בלתי תלויים, ולכן:

$$X \sim \mathrm{Erlang}(3, 2) = \mathrm{Gamma}(3, 2).$$

2 אם $X \sim \mathrm{Gamma}(5, 2)$, חשבו את התוחלת והשונות.

$$E[X] = \frac{\alpha}{\lambda} = \frac{5}{2} = 2.5$$

$$\mathrm{Var}(X) = \frac{\alpha}{\lambda^2} = \frac{5}{2^2} = \frac{5}{4} = 1.25.$$

3 הסבירו במילים מה ההבדל בין $\mathbf{Gamma}(\alpha, \lambda)$ לבין $\mathbf{Erlang}(k, \lambda)$.

Erlang היא מקרה פרטי של Gamma שבו פרמטר הצורה הוא מספר שלם חיובי: $k \in \mathbb{N}$.
ב־Gamma הכללית, פרמטר הצורה α יכול להיות גם לא שלם.

תרגילי חשיבה קצרים

1 למה במקרה רציף בדרך כלל מתקיים $P(X = x) = 0$, אבל עדיין ייתכן ש־ $P(a \le X \le b) > 0$?

כי הסתברות רציפה נמדדת כשטח. לנקודה בודדת אין רוחב ולכן השטח שלה אפס, אבל לקטע יש רוחב ולכן יכול להיות תחתיו שטח חיובי.

2 מתי נעדיף להשתמש בהתפלגות בינומית ומתי בגיאומטרית?

בינומית מתאימה כשמספר הניסויים קבוע מראש ושואלים כמה הצלחות היו. גיאומטרית מתאימה כששואלים כמה ניסיונות דרושים עד ההצלחה הראשונה.

3 לפי משפט הגבול המרכזי, למה ממוצע של הרבה מדידות נוטה להיראות נורמלי?

כי סכומים וממוצעים של הרבה משתנים בלתי תלויים, בתנאים מתאימים, מתקרבים להתפלגות נורמלית גם אם המשתנים המקוריים אינם נורמליים.